

Tiến hóa tuần tự vận chuyển–nguồn có điều kiện khí tượng cho dự báo PM_{2.5} hạn dài

Loc Phan

Nguyen Tat Thanh University, Vietnam

Tóm tắt nội dung

Dự báo PM_{2.5} trong 72 giờ không chỉ đòi hỏi nhận ra tương quan không gian–thời gian, mà còn phải mô tả cách trường nồng độ đã dự báo tiếp tục biến đổi ở từng bước kế tiếp. Tuy vậy, nhiều mô hình sinh đồng thời toàn bộ chân trời từ một biểu diễn lịch sử cố định, nên trạng thái dự báo ở giờ trước không trực tiếp trở thành điều kiện của giờ sau. Nghiên cứu này đặt lại bài toán như một quá trình tiến hóa rời rạc và đề xuất toán tử hồi quy vận chuyển–nguồn (TSR). Ở mỗi bước ba giờ, TSR cộng vào trường PM_{2.5} hiện tại hai thành phần: vận chuyển theo gió trên đồ thị tám láng giềng và nguồn/mất mát gồm mức chung toàn vùng cùng độ lệch riêng từng trạm. Thành phần vận chuyển và phần nguồn cục bộ được ép có tổng bằng không trên các trạm; đây là ràng buộc lấy cảm hứng từ bảo toàn, không phải định luật bảo toàn khối lượng tuyệt đối.

Thí nghiệm có kiểm soát trên KnowAir dùng 184 trạm, lịch sử 72 giờ, chân trời 72 giờ, chia thời gian 50/25/25 và ba hạt giống ngẫu nhiên. Trong thiết lập chuẩn chính, TSR, đối chứng trực tiếp và mã công khai của AirDDE đều nhận khí tượng đã quan trắc trong 72 giờ đích; các biến thể chỉ dùng lịch sử được đánh giá riêng. Trên tập xác thực, TSR đạt MAE 16.7630 ± 0.0252 , thấp hơn mô hình dự báo trực tiếp gần bằng số tham số ở mức 18.8620 ± 0.0457 . Trên tập kiểm tra, ba mô hình đơn đạt 16.1266 ± 0.0348 , thấp hơn 4,7% so với điểm MAE 16.92 do AirDDE công bố dưới cùng tập thông tin và giao thức KnowAir cốt lõi; vì AirDDE không phát hành dự báo hay thống kê nhiều hạt giống, đây là so sánh điểm chứ không phải kiểm định ghép cặp. Trung bình đều ba mô hình TSR đạt MAE/RMSE/sMAPE là 15.8205/24.3253/0.3721. Trên Beijing Multi-Site độc lập gồm 12 trạm, TSR giảm điểm ước lượng MAE kiểm tra từ 32.522 xuống 30.873 và sMAPE từ 0.546 xuống 0.477, dù RMSE tăng từ 51.196 lên 52.079. Khoảng tin cậy theo khối thời gian của chênh lệch MAE Beijing còn cắt 0, cho thấy lợi ích ngoài mẫu cần được kiểm chứng tiếp trên các mạng trạm khác.

Từ khóa: PM_{2.5}; dự báo có điều kiện khí tượng; dự báo nhiều bước; tiến hóa trạng thái; đồ thị theo gió; nguồn và mất mát.

1 Đặt vấn đề

Một dự báo ba giờ và một dự báo ba ngày có thể dùng cùng dữ liệu đầu vào, nhưng không phải cùng một bài toán. Ở chân trời ngắn, mô hình chủ yếu nội suy quán tính gần nhất của nồng độ và khí tượng. Khi chân trời kéo dài, mỗi sai lệch ở trạng thái trung gian lại làm đổi điều kiện ban đầu của bước sau. Nếu toàn bộ 24 mốc tương lai được sinh trực tiếp từ một biểu diễn lịch sử cố định, mối liên hệ này chỉ tồn tại ngầm trong tham số, chứ không được thể hiện như một quy luật chuyển trạng thái.

Các mạng đồ thị đã cải thiện dự báo không khí bằng cách mô tả quan hệ giữa trạm, từ đồ thị tích chập kết hợp bộ nhớ dài–ngắn hạn [Qi et al., 2019], đồ thị có tri thức miền trên KnowAir [Wang et al., 2020], đến cấu trúc phân cấp và phụ thuộc xa [Xu et al., 2021, Chen et al., 2024b]. Gần đây, AirFormer dùng chú ý không gian–thời gian và biến ẩn để mô tả bất định trên quy mô quốc gia [Liang et al., 2023]. Những tiến bộ này rất quan trọng, nhưng chúng chưa tự trả lời một câu hỏi cơ chế: *việc bắt buộc trường ô nhiễm tiến hóa tuần tự có tạo lợi ích riêng ở chân trời dài hay không?*

Các mô hình có định hướng vật lý tiếp cận câu hỏi từ phương trình khuếch tán–bình lưu. Có công trình đưa phương trình phân tán vào hàm mất mát [Zhou et al., 2022], có công trình dùng phương trình vi phân nơ-ron để biểu diễn khuếch tán và bình lưu [Hettige et al., 2024], hoặc tách nhánh động lực vật lý và nhánh học từ dữ liệu trong một hệ mở [Tian et al., 2025]. AirDDE tiến thêm một bước khi mô hình hóa độ trễ lan truyền bằng phương trình vi phân có trễ, bộ nhớ toàn cục/cục bộ và hàm tiến hóa gồm khuếch tán, bình lưu trễ, nguồn/mất mát [Wu et al., 2026]. Nghiên cứu này xét một câu hỏi bổ sung: liệu phép tiến hóa rời rạc, được phân rã tối giản thành vận chuyển và nguồn/mất mát, có tạo lợi ích dự báo dài trong một thiết lập có kiểm soát hay không.

Ý tưởng trung tâm được viết gọn như sau:

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + \mathbf{T}_\theta(\hat{\mathbf{x}}_k, \mathbf{m}_k, \mathcal{G}) + \mathbf{S}_\phi(\hat{\mathbf{x}}_k, \mathbf{m}_k), \quad (1)$$

trong đó $\mathbf{T}_\theta$ tái phân bố nồng độ giữa các trạm, còn $\mathbf{S}_\phi$ biểu diễn tích tụ hoặc suy giảm không bảo toàn trong miền quan sát. Cách viết này không khẳng định đã nhận dạng đúng từng quá trình hóa học. Giả thuyết trung tâm có thể kiểm tra trực tiếp: nếu tiến hóa tuần tự không cần thiết, mô hình trực tiếp cùng dung lượng phải đạt kết quả tương đương.

Nghiên cứu có bốn đóng góp:

1. Đề xuất một công thức hồi quy vận chuyển–nguồn cho dự báo PM_{2.5} nhiều bước, trong đó trường dự báo ở mỗi bước trở thành trạng thái đầu vào của bước kế tiếp.
2. Xây dựng phân rã có diễn giải giữa vận chuyển tổng bằng không trên các trạm và nguồn/mất mát gồm thành phần chung cùng thành phần cục bộ tổng bằng không.
3. Chứng minh bằng huấn luyện lại với ba hạt giống rằng lợi ích không thể quy đơn thuần cho số tham số: mô hình trực tiếp 72,630 tham số kém toán tử hồi quy 72,435 tham số 2.0990 MAE trên tập xác thực.
4. Mở rộng đánh giá sang mạng 12 trạm Beijing Multi-Site và định lượng bất định theo thời gian bằng phương pháp lấy mẫu lại ghép cặp theo các khối một, hai và bốn tuần.

2 Công trình liên quan

2.1 Dự báo không gian–thời gian trên mạng trạm

Mạng quan trắc chất lượng không khí tạo ra chuỗi đa biến trên một tập vị trí không đều. Vì vậy, đồ thị là biểu diễn tự nhiên hơn lưới đều: đỉnh là trạm, cạnh có thể dựa trên khoảng cách, tương quan hoặc hướng gió. Trong dự báo không gian–thời gian nói chung, DCRNN lan truyền tín hiệu theo khuếch tán trên đồ thị, STGCN và ASTGCN dùng tích chập không gian–thời gian, còn MTGNN học quan hệ giữa các chuỗi thay vì cố định đồ thị trước [Li et al., 2018, Yu et al., 2018, Guo et al., 2019, Wu et al., 2020]. MegaCRN và HimNet tiếp tục đưa bộ nhớ nguyên mẫu và tham số thích nghi theo dị thể vào dự báo nhiều bước [Jiang et al., 2023b, Dong et al., 2024]. Các kiến trúc này là đối chứng quan trọng trong công bố AirDDE, nhưng bản thân điểm số của chúng không trả lời liệu trạng thái ô nhiễm dự báo có cần được tiến hóa theo một phép chuyển có cấu trúc hay không.

Trong chất lượng không khí, GC-LSTM kết hợp tích chập đồ thị với bộ nhớ dài–ngắn hạn để học phụ thuộc không gian và thời gian [Qi et al., 2019]. PM_{2.5}-GNN đưa tri thức miền về khoảng cách, địa hình và khí tượng vào đồ thị, đồng thời giới thiệu bộ dữ liệu KnowAir gồm 184 thành phố [Wang et al., 2020]. HighAir tổ chức đồ thị theo cấp thành phố và trạm, còn GAGNN học nhóm thành phố để mở rộng tầm phụ thuộc [Xu et al., 2021, Chen et al., 2024b].

Một hướng khác dùng cơ chế chú ý để tránh giới hạn trường tiếp nhận của truyền thông điệp. Crossformer khai thác phụ thuộc chéo giữa các chiều, PDFormer biểu diễn độ trễ lan truyền, còn iTransformer đảo vai trò của biến và thời gian trong cơ chế chú ý [Zhang and Yan, 2023, Jiang et al., 2023a, Liu et al., 2024]. STMFormer bổ sung học tự giám sát cho quan hệ không gian–thời gian [Li et al., 2025]. Riêng AirFormer tách tầng dự báo xác định và tầng bất định, đồng thời thiết kế chú ý không gian dạng bia tiêu cho mạng trạm quy mô lớn [Liang et al., 2023]. Điểm chung của nhóm này là làm giàu biểu diễn quan hệ; bài báo hiện tại bổ sung một trục khác, trong đó trạng thái dự báo được cập nhật tuần tự bằng một toán tử có cấu trúc.

2.2 Động lực có định hướng vật lý

Trong khí quyển, nồng độ quan trắc chịu đồng thời bình lưu, khuếch tán, phát thải, lắng đọng, phản ứng và trao đổi qua biên [Seinfeld and Pandis, 2016]. Mô hình học máy khó nhận dạng riêng từng quá trình khi chỉ có nồng độ tại trạm và một số biến khí tượng. Vì vậy, chúng tôi dùng từ *có cấu trúc vật lý* thay vì *mô phỏng vật lý chính xác*.

Các nghiên cứu gần đây đã đưa phương trình vào mạng theo nhiều mức. STGODE và SGOODE mô hình hóa động lực đồ thị liên tục bằng phương trình vi phân thường; STG-NCDE dùng phương trình vi phân có điều khiển, còn STDDE đưa độ trễ vào động lực không gian–thời gian [Fang et al., 2021, Chen et al., 2024a, Choi et al., 2022, Long et al., 2024]. Trong chất lượng không khí, Zhou và cộng sự dùng phương trình bình lưu–khuếch tán như ràng buộc huấn luyện [Zhou et al., 2022]. AirPhyNet biểu diễn khuếch tán và bình lưu bằng mạng phương trình vi phân [Hettige et al., 2024]; Air-DualODE xem miền không khí như hệ mở và kết hợp nhánh động lực vật lý với nhánh bù học từ dữ liệu [Tian et al., 2025]. Các cách tiếp cận này dựa trên nền tảng phương trình vi phân nơ-ron [Chen et al., 2018]. Phương pháp của chúng tôi dùng bước thời gian đúng bằng nhịp dữ liệu ba giờ, tránh bộ giải số liên tục và tập trung vào kiểm chứng vai trò của phân rã vận chuyển–nguồn.

2.3 Tác động ngoại sinh tương lai

Mô tả trên giấy và mã công khai của AirDDE không nhất quán về tập thông tin. Phương trình bài toán của AirDDE chỉ ghi nồng độ và yếu tố phụ trợ đến thời điểm hiện tại, $\tilde{X}_{T+1:T+H} = F(X_{1:T}, M_{1:T}; \Theta)$, và phần phương pháp nhiều lần gọi các yếu tố này là lịch sử [Wu et al., 2026]. Tuy nhiên, kiểm toán mã công khai cho thấy bộ nạp dữ liệu tạo cửa sổ đích

gồm cả nhân và khí tượng, sau đó tách các kênh khí tượng tại $T + 1:T + H$ thành y_{cov} ; mô hình dùng tensor này trong hạng nguồn/mất mát và ở mỗi bước giải mã. Vì vậy, giao thức thực thi của AirDDE điều kiện hóa trên khí tượng đích đã quan trắc, giống tập thông tin chính của chúng tôi. Hai cách cài đặt chỉ khác biểu diễn hướng gió: AirDDE chuẩn hóa góc theo độ, còn chúng tôi dùng sin/cos để tôn trọng tính tuần hoàn. Đây là khác biệt tiền xử lý, không phải lợi thế về thông tin sẵn có.

3 Phát biểu bài toán và tập thông tin

Giả sử có N trạm. Tại thời điểm t , $\mathbf{x}_t \in \mathbb{R}^N$ là nồng độ PM_{2.5} và $\mathbf{m}_t \in \mathbb{R}^{N \times d_m}$ là khí tượng. Với lịch sử dài L và chân trời H , mục tiêu là

$$\widehat{\mathbf{X}}_{t+1:t+H} = F_{\Theta}(\mathbf{X}_{t-L+1:t}, \mathbf{M}_{t-L+1:t}, \mathcal{I}_{ngoại\ sinh}), \quad (2)$$

với $\widehat{\mathbf{X}}_{t+1:t+H} \in \mathbb{R}^{H \times N}$. Hai tập thông tin phải được phân biệt:

$$\mathcal{I}_{ls} = \{\mathbf{X}_{t-L+1:t}, \mathbf{M}_{t-L+1:t}\}, \quad (3)$$

$$\mathcal{I}_{ht} = \mathcal{I}_{ls} \cup \{\mathbf{M}_{t+1:t+H}\}. \quad (4)$$

Ký hiệu “ls” chỉ lịch sử; “ht” chỉ thông tin khí tượng đã hiện thực hóa trong giai đoạn đích. Kết quả chính dùng $\mathcal{I}_{ht}$ và vì thế đo chất lượng dự báo PM_{2.5} có điều kiện trên quỹ đạo khí tượng đúng. Các thí nghiệm chỉ dùng $\mathcal{I}_{ls}$ được báo cáo riêng để xác định ảnh hưởng của việc không biết khí tượng tương lai.

4 Phương pháp

4.1 Tổng quan

Hình 1 cho thấy toàn bộ luồng tính toán. Hai bộ mã hóa có cổng hồi quy (GRU) [Cho et al., 2014] tóm tắt 72 giờ lịch sử ở hai thang: mức trung bình toàn mạng và phần lệch của từng trạm. Từ trạng thái PM_{2.5} cuối lịch sử, mô hình lặp 24 lần. Mỗi lần, khí tượng ở bước tương ứng điều khiển trọng số theo gió và các ô hồi quy; hai đầu ra vận chuyển và nguồn/mất mát được cộng vào trạng thái hiện tại.

4.2 Mã hóa mức chung và mức cục bộ

Với lịch sử $\mathbf{x}_{t-L+1:t}$, ta tách

$$\bar{\mathbf{x}}_{\tau} = \frac{1}{N} \sum_{i=1}^N x_{i,\tau}, \quad r_{i,\tau} = x_{i,\tau} - \bar{x}_{\tau}. \quad (5)$$

Một GRU dùng chuỗi $\bar{\mathbf{x}}_{\tau}$ cùng khí tượng trung bình trạm để tạo trạng thái ẩn chung $\mathbf{h}_0^g$. GRU thứ hai dùng $r_{i,\tau}$ và khí tượng tại trạm để tạo $\mathbf{h}_{i,0}^{\ell}$. Các tham số GRU cục bộ được dùng chung giữa mọi trạm; một véc-tơ nhúng trạm tám chiều giữ lại khác biệt vị trí. Sự phân tách này giúp đầu nguồn/mất mát biểu diễn riêng thay đổi nền toàn vùng và sai lệch tại chỗ.

4.3 Đồ thị và đổi mới theo gió

Mỗi trạm i nối với tám trạm gần nhất. Với khoảng cách cung lớn d_{ij} , trọng số nền là

$$w_{ij}^0 \propto \exp\left(-\frac{d_{ij}}{250 \text{ km}}\right). \quad (6)$$

Gọi $\mathbf{b}_{j \rightarrow i}$ là véc-tơ đơn vị từ j đến i , và $\mathbf{v}_{j,k}$ là hướng chuyển động của khối khí tại j . Trọng số theo gió được xác định bởi

$$a_{ij,k} = \frac{w_{ij}^0 [\mathbf{b}_{j \rightarrow i}^{\top} \mathbf{v}_{j,k}]_+}{\sum_{q \in \mathcal{N}(i)} w_{iq}^0 [\mathbf{b}_{q \rightarrow i}^{\top} \mathbf{v}_{q,k}]_+}, \quad (7)$$

Bảng 1. Định vị cấu trúc của một số phương pháp gần nhất. Bảng mô tả cách xây dựng mô hình, không phải bảng xếp hạng và không hàm ý các giao thức đầu vào giống nhau.

Phương pháp	Dạng tiến hóa	Quan hệ không gian	Phân rã động lực	Khí tượng trong công thức dự báo
PM2.5-GNN	Rời rạc, dựa trên bộ mã hóa	Đồ thị có tri thức miền	Không tách vận chuyển và nguồn/mất mát	Theo giao thức bài gốc
AirFormer	Dự báo bằng bộ biến đổi	Chú ý không gian dạng bìa tiêu	Không tách theo quá trình vật lý	Theo giao thức bài gốc
AirPhyNet	Liên tục	Đồ thị trạm	Khuếch tán và bình lưu	Theo giao thức bài gốc
Air-DualODE	Hai hệ liên tục	Đồ thị trạm	Nhánh vật lý và nhánh bù dữ liệu	Theo giao thức bài gốc
AirDDE	Liên tục	Khoảng cách và trường gió	Khuếch tán, bình lưu và nguồn/mất mát	Công thức: lịch sử; mã: khí tượng đích đã quan trắc
TSR	Rời rạc, hồi quy	Đồ thị tám láng giềng theo gió	Vận chuyển tổng bằng không và nguồn/mất mát	Khí tượng đích đã quan trắc

Bảng 2. Ký hiệu chính. “Trung bình trạm” luôn là trung bình số học trên N vị trí, không phải trung bình theo diện tích hay khối lượng không khí.

Ký hiệu	Ý nghĩa
N, L, H	Số trạm, số bước lịch sử và số bước dự báo. Trong KnowAir: 184, 24, 24.
x_t	Trường nồng độ PM _{2.5} tại một thời điểm, kích thước N .
$\mathbf{m}_t$	Sáu biến khí tượng lõi tại các trạm: nhiệt độ, áp suất, độ ẩm tương đối, tốc độ gió, sin và cos của hướng gió.
$\mathcal{G}$	Đồ thị tám láng giềng gần nhất, trọng số nền suy giảm theo khoảng cách.
T_k	Gia số vận chuyển ở bước k , thỏa $\sum_i T_{i,k} = 0$.
S_k	Gia số nguồn/mất mát, gồm mức chung S_k^g và độ lệch cục bộ $S_{i,k}^\ell$.

trong đó $[z]_+ = \max(z, 0)$. Nếu mọi tích vô hướng đều bằng không, mô hình quay về trọng số khoảng cách đã chuẩn hóa. Đối mới không gian tại trạm i là

$$q_{i,k} = \sum_{j \in \mathcal{N}(i)} a_{ij,k} \widehat{x}_{j,k} - \widehat{x}_{i,k}. \quad (8)$$

Đầu vận chuyển nhận $q_{i,k}$, tốc độ gió và trạng thái ẩn cục bộ, rồi tạo gia số bị chặn bằng hàm tanh. Sau cùng, trung bình trạm được trừ đi:

$$\widetilde{T}_{i,k} = c \tanh f_\theta(\mathbf{h}_{i,k}^\ell, q_{i,k}, v_{i,k}), \quad T_{i,k} = \widetilde{T}_{i,k} - \frac{1}{N} \sum_j \widetilde{T}_{j,k}, \quad (9)$$

với $c = 0.5$ theo đơn vị mục tiêu đã chuẩn hóa. Như vậy $\sum_i T_{i,k} = 0$. Điều kiện này chỉ nói toán tử không tự nâng hoặc hạ trung bình số học trên mạng trạm; nó không bảo toàn khối lượng vì các trạm không đại diện cho những thể tích khí bằng nhau.


4.4 Nguồn/mất mát chung và cục bộ

Khối nguồn/mất mát được phân rã:

$$S_{i,k} = S_k^g + S_{i,k}^\ell, \quad \sum_{i=1}^N S_{i,k}^\ell = 0. \quad (10)$$

Trạng thái ẩn chung được cập nhật bằng trung bình PM_{2.5} hiện tại và khí tượng trung bình mạng. Đầu chung sinh S_k^g , có thể làm tăng hoặc giảm mức nền toàn vùng. Trạng thái ẩn cục bộ nhận phần dư $\widehat{x}_{i,k} - \bar{x}_k$, khí tượng trạm, đối mới theo gió và véc-tơ nhúng trạm. Đầu cục bộ sinh $S_{i,k}^\ell$; trừ trung bình trạm cho kết quả $S_{i,k}^\ell$. Mỗi đầu dùng hai lớp tuyến tính với kích hoạt GELU và đầu ra tanh bị chặn. Trạng thái kế tiếp tuân theo Phương trình (1).

Tên “nguồn/mất mát” ở đây là định nghĩa vận hành: phần biến đổi nồng độ không được gán cho tái phân bố không gian tổng bằng không. Nó có thể gộp phát thải, lắng đọng, phản ứng, pha loãng lớp biên, trao đổi qua biên miền và cả sai số mô hình chưa phân giải. Vì dữ liệu không chứa kiểm kê phát thải đầy đủ, chúng tôi không diễn giải S như phép đo trực tiếp một quá trình hóa học riêng lẻ.



Hình 1. Kiến trúc TSR. (a) Lịch sử được phân rã thành mức chung và phần lệch cục bộ để khởi tạo hai trạng thái ẩn. (b) Khí tượng đã hiện thực hóa ở bước đích k được đưa vào tường minh; đổi mới theo gió và các trạng thái GRU sinh gia số vận chuyển T_k và nguồn/mất mát S_k . Phương trình cập nhật là điểm cuối của mỗi bước ba giờ và đầu vào của bước kế tiếp.

4.5 Hàm mục tiêu

Mọi sai số được tính trên các điểm có nồng độ thật ít nhất $10^{-4} \mu\text{g m}^{-3}$. Gọi ℓ_1 là MAE có mặt nạ, $\bar{y}$ là trung bình trạm, $y' = y - \bar{y}$, và Δy là gia số theo thời gian. Hàm mất mát là

$$\mathcal{L} = \ell_1(\hat{y}, y) + 0.25 \ell_1(\bar{\hat{y}}, \bar{y}) + 0.25 \ell_1(\hat{y}', y') + 0.10 \ell_1(\Delta \hat{y}, \Delta y). \quad (11)$$

Hai hạng giữa giữ cân bằng giữa nền vùng và cấu trúc cục bộ; hạng cuối khuyến khích quỹ đạo có gia số đúng thay vì chỉ khớp từng mốc độc lập.

5 Thiết kế thực nghiệm

5.1 Dữ liệu và chia tập

KnowAir bao phủ 184 thành phố của Trung Quốc từ ngày 1/1/2015 đến 31/12/2018, nhịp ba giờ, gồm PM_{2.5} và 17 thuộc tính khí tượng [Wang et al., 2020]. Mạng phát hành có kích thước $11,688 \times 184 \times 18$. Nghiên cứu dùng PM_{2.5} làm mục tiêu và sáu kênh khí tượng lõi: nhiệt độ 2 m, áp suất bề mặt, độ ẩm tương đối ở 950 hPa, tốc độ gió 100 m, sin và cos của hướng gió 100 m. Biểu diễn tròn bằng sin/cos tránh điểm gián đoạn giữa 0° và 360° .

Dữ liệu được chia theo thời gian 50/25/25, tương ứng 5.844/2.922/2.922 bước. Cửa sổ không đi qua ranh giới tập. Sau khi dành 24 bước lịch sử và 24 bước đích, số cửa sổ huấn luyện/xác thực/kiểm tra là 5.797/2.875/2.875. Trung bình và độ lệch chuẩn của từng kênh được ước lượng chỉ trên nửa huấn luyện, gộp thời gian và trạm, rồi áp dụng cho các tập sau.

5.2 Đối chứng ngoài Beijing Multi-Site

Đối chứng ngoài dùng Beijing Multi-Site Air Quality, một bộ dữ liệu độc lập gồm 12 trạm quan trắc từ tháng 3/2013 đến tháng 2/2017 với PM_{2.5} và khí tượng theo giờ [Chen, 2017]. Để giữ cùng chân trời với KnowAir, chúng tôi lấy một mốc sau mỗi ba giờ, thu được 11.688 bước. Sáu kênh khí tượng đích gồm nhiệt độ, áp suất bề mặt, độ ẩm tương đối suy ra từ nhiệt độ và điểm sương bằng công thức Magnus, tốc độ gió, sin và cos của hướng gió. Bộ dữ liệu này chỉ có gió gần bề mặt thay vì gió 100 m; đây là một dịch chuyển miền có chủ ý, không phải phép sao chép KnowAir sang các trạm khác.

Khoảng 2,1% giá trị PM_{2.5} tại các mốc ba giờ bị thiếu. Mặt nạ quan trắc được giữ xuyên suốt hàm mất mát và phép tính chỉ số, nên giá trị điền không được xem là nhân thật. Riêng đầu vào lịch sử bị thiếu được điền tiến theo thời gian; trung vị chỉ từ tập huấn luyện được dùng nếu chuỗi mở đầu bằng khoảng trống. Dữ liệu được chia tuần tự 70/10/20, tương ứng 8.134/1.122/2.291 cửa sổ huấn luyện, xác thực và kiểm tra. Cả đối chứng trực tiếp lẫn TSR nhận cùng lịch sử 72 giờ và khí tượng đã quan trắc trong 72 giờ đích. Kiến trúc, hạt giống và quy tắc dừng được cố định trước; mã băm của sáu điểm kiểm tra cùng quy tắc diễn giải được lưu trước lần đọc duy nhất của 20% cuối.

Bảng 3. Giao thức KnowAir. Tập kiểm tra không được dùng để chọn siêu tham số.

Thuộc tính	Giá trị
Mục tiêu	PM _{2.5} tại 184 trạm
Khoảng thời gian	1/1/2015–31/12/2018
Nhịp lấy mẫu	3 giờ
Lịch sử L / chân trời H	24 / 24 bước (72 / 72 giờ)
Chia thời gian	50% huấn luyện, 25% xác thực, 25% kiểm tra
Cửa sổ hợp lệ	5.797 / 2.875 / 2.875
Khí tượng giai đoạn đích	Giá trị đã quan trắc; phải công bố khi so sánh
Chuẩn hóa	Thống kê chỉ từ tập huấn luyện
Hạt giống	42, 43, 44

5.3 Mô hình đối chứng

Đối chứng chính là bộ dự báo trực tiếp mức chung/cục bộ. Mô hình mã hóa cùng lịch sử và sinh gia số cho cả 24 chân trời từ biểu diễn cố định; dự báo tại bước k không được đưa lại làm đầu vào của bước $k + 1$. Đối chứng trực tiếp và TSR nhận đúng cùng lịch sử PM_{2.5}, cùng sáu biến khí tượng lịch sử và cùng trường khí tượng đã quan trắc trong 24 bước đích. Khác biệt về tập thông tin vì thế không thể giải thích chênh lệch giữa hai mô hình. Kích thước ẩn, nhúng chân trời và nhúng trạm được tăng để đối chứng có 72.630 tham số, gần bằng 72.435 tham số của TSR. So sánh này kiểm soát số tham số và tập thông tin; tốc độ học được chọn riêng trên tập xác thực cho từng kiến trúc.

5.4 Huấn luyện và chỉ số

Mỗi mô hình được huấn luyện tối đa 30 vòng bằng AdamW [Loshchilov and Hutter, 2019], suy giảm trọng số 10^{-5} , cỡ lô 256 và cắt chuẩn đạo hàm ở 5. Tốc độ học ban đầu là 10^{-3} cho các biến thể TSR và 3×10^{-3} cho đối chứng trực tiếp khớp dung lượng. Tốc độ học giảm một nửa khi MAE xác thực ngừng cải thiện; huấn luyện dừng sớm sau sáu vòng không cải thiện. Điểm kiểm tra mô hình có MAE xác thực thấp nhất được giữ. Không có siêu tham số nào trong ma trận chính được chọn trên tập kiểm tra.

Với P điểm hợp lệ, các chỉ số là

$$\text{MAE} = \frac{1}{P} \sum_{p=1}^P |y_p - \hat{y}_p|, \quad (12)$$

$$\text{RMSE} = \sqrt{\frac{1}{P} \sum_{p=1}^P (y_p - \hat{y}_p)^2}, \quad (13)$$

$$\text{sMAPE} = \frac{1}{Q} \sum_{q=1}^Q \frac{|y_q - \hat{y}_q|}{(|y_q| + |\hat{y}_q|)/2 + 10^{-8}}. \quad (14)$$

MAE và RMSE dùng mặt nạ điểm thật khác không; sMAPE “chính thức” dùng toàn bộ Q điểm để tương thích mốc công bố AirDDE. Với Beijing, cả ba chỉ số loại các nhân bị thiếu theo mặt nạ quan trắc. MAE là chỉ số chọn mô hình và các bảng báo trung bình $\pm$ độ lệch chuẩn qua ba hạt giống.

Để không xem các cửa sổ chồng lấn là độc lập, chúng tôi còn tính một chuỗi sai số theo gốc dự báo. Tại gốc t , MAE được lấy trên mọi chân trời và trạm hợp lệ, sau đó lấy trung bình qua ba hạt giống. Với hai mô hình A và B , chuỗi ghép cặp là $d_t = \text{MAE}_t(A) - \text{MAE}_t(B)$. Khoảng tin cậy 95% dùng 10.000 lần lấy mẫu lại theo khối tròn, với độ dài 56, 112 và 224 gốc, lần lượt tương ứng một, hai và bốn tuần ở nhịp ba giờ. Chúng tôi báo phân vị 2,5/97,5% và giá trị p hai phía từ phân phối lấy mẫu lại; kết luận không dựa vào một độ dài khối duy nhất.

6 Kết quả

6.1 Tiến hóa tuần tự so với dự báo trực tiếp

Bảng 4 là phép so sánh trung tâm, hoàn toàn trên tập xác thực. TSR giảm MAE từ 18.8620 xuống 16.7630 so với đối chứng trực tiếp gần bằng số tham số; mức giảm 2.0990 $\mu\text{g m}^{-3}$ xuất hiện ổn định qua ba hạt giống. Đây là so sánh giữa hai cách sinh quỹ đạo dùng cùng dữ liệu đầu vào, trong đó TSR cuộn tiến trạng thái còn đối chứng sinh trực tiếp toàn bộ chân trời.

6.2 Kiểm định theo thời gian và đối chứng ngoài

Bảng 5 cho thấy cùng giả thuyết cơ chế trên Beijing Multi-Site. Trên 20% cuối được mở sau khi khóa điểm kiểm tra, TSR có MAE thấp hơn đối chứng trực tiếp 1.6494 $\mu\text{g m}^{-3}$ (5,1%) và sMAPE thấp hơn 0,0687 (12,6%). Đổi lại, RMSE tăng 0.8830 $\mu\text{g m}^{-3}$ (1,7%), cho thấy toán tử giảm sai số điển hình nhưng chưa kiểm soát tốt bằng đối chứng ở một số sai số lớn. Hướng của MAE lặp lại trên tập xác thực và kiểm tra, nhưng độ biến thiên theo thời gian vẫn phải được xét trước khi gọi đây là xác nhận ngoài mẫu.

Bảng 5. Đối chứng ngoài trên Beijing Multi-Site với cùng tập thông tin. Số là trung bình $\pm$ độ lệch chuẩn qua ba hạt giống; mọi chỉ số loại nhân bị thiếu.

Mô hình	MAE xác thực	MAE kiểm tra	RMSE kiểm tra	sMAPE kiểm tra
Trực tiếp, khớp dung lượng	33.371 $\pm$ 0.750	32.522 $\pm$ 0.494	51.196 $\pm$ 0.291	0.546 $\pm$ 0.014
TSR	31.883 $\pm$ 0.479	30.873 $\pm$ 0.536	52.079 $\pm$ 0.843	0.477 $\pm$ 0.005

Trên Beijing, TSR có MAE thấp hơn ở 64,9% gốc dự báo và chênh lệch trung bình theo gốc là 1.6584 $\mu\text{g m}^{-3}$, nhưng cận dưới vẫn nhỏ hơn 0 ở cả ba độ dài khối trong Bảng 6. Theo quy tắc diễn giải đã khóa trước khi mở tập kiểm tra, kết quả này được xem là một lần lặp lại có triển vọng, chưa phải bằng chứng kết luận về mọi giai đoạn thời gian.

Bảng 6. Độ nhạy của kiểm định ghép cặp theo khối thời gian. Δ MAE $>$ 0 có lợi cho mô hình đứng sau dấu trừ.

Dữ liệu và cặp so sánh	Độ dài khối	Δ MAE	Khoảng tin cậy 95%	p hai phía
Beijing kiểm tra: trực tiếp – TSR	1 tuần	1.6584	[−0.0094, 3.1954]	0.0516
	2 tuần	1.6584	[−0.0527, 3.2084]	0.0568
	4 tuần	1.6584	[−0.3721, 3.3919]	0.1040

MAE theo gốc cho mỗi gốc trọng số bằng nhau; vì vậy chênh lệch Beijing 1.6584 hơi khác hiệu hai MAE tính trên toàn bộ điểm hợp lệ ở Bảng 5. Mỗi khoảng dùng 10.000 mẫu theo khối tròn.

6.3 Kết quả kiểm tra và ranh giới so sánh

Để đặt TSR vào toàn cảnh đối chứng, Bảng 7 tổ chức lại toàn bộ 19 mô hình và AirDDE trong phần KnowAir của Bảng 2 công bố AirDDE [Wu et al., 2026]. Phân loại trình bày gồm dự báo không gian–thời gian tổng quát, mô hình chuyên cho chất lượng không khí, động lực nơ-ron hoặc có định hướng vật lý, rồi AirDDE như mốc tham chiếu mạnh nhất. Các số này do AirDDE tổng hợp hoặc chạy lại, không phải kết quả tái lập của nghiên cứu này. Với các đối chứng không có mã đường dữ liệu được kiểm toán ở đây, chúng tôi không suy đoán việc chúng có đọc khí tượng đích hay không.

Kiểm toán mã cài đặt AirDDE xác nhận AirDDE và TSR cùng dùng 24 bước lịch sử, 24 bước đích, phép chia 50/25/25, chuẩn hóa chỉ từ tập huấn luyện và khí tượng đã quan trắc trong toàn bộ giai đoạn đích. Do đó, so sánh trực tiếp hai dòng này là đồng nhất về tập thông tin và giao thức dữ liệu cốt lõi. Trung bình ba mô hình đơn TSR đạt MAE 16.1266, thấp hơn 0.7934 $\mu\text{g m}^{-3}$ (4,7%) so với điểm 16.92 của AirDDE. Tuy nhiên, AirDDE chỉ công bố số tổng hợp và không cung cấp dự báo khớp theo từng cửa sổ hay phân phối nhiều hạt giống, nên chênh lệch này là so sánh điểm trên cùng giao thức, chưa phải bằng chứng ưu thế thống kê ghép cặp. Dòng ensemble được báo riêng và không dùng để tính mức giảm 4,7%.

Bảng 4. So sánh trung tâm trên tập xác thực KnowAir qua ba hạt giống. Đơn vị MAE là $\mu\text{g m}^{-3}$; Δ được tính so với TSR.

Mô hình	Số tham số	MAE 1–72 giờ	Δ MAE
Trực tiếp, khớp dung lượng	72.630	18.8620 ± 0.0457	+2.0990
TSR	72.435	16.7630 ± 0.0252	—

Bảng 7. Các đối chứng KnowAir đã công bố và kết quả TSR. AirDDE và TSR dùng cùng khí tượng đã hiện thực hóa trong 72 giờ đích theo mã công khai; trạng thái đầu vào tương lai của các đối chứng khác không được suy đoán khi chưa kiểm toán mã.

Họ phương pháp	Mô hình	MAE	RMSE	sMAPE
<i>Khối A — Các số do AirDDE tổng hợp hoặc chạy lại</i>				
Dự báo không gian–thời gian	DCRNN (2018) [†]	24.02	37.87	0.53
	STGCN (2018) [†]	23.64	32.48	0.52
	ASTGCN (2019) [†]	19.92	31.39	0.44
	MTGNN (2020)	18.92	30.34	0.41
	Crossformer (2023)	21.11	32.97	0.44
	PDFormer (2023)	19.06	30.66	0.41
	iTransformer (2024)	21.03	33.14	0.46
	STMFormer (2025)	19.57	31.12	0.44
Chuyên cho chất lượng không khí	PM2.5-GNN (2020) [†]	19.32	30.12	0.43
	GAGNN (2023)	20.71	32.88	0.42
	AirFormer (2023) [†]	19.17	30.19	0.43
	MegaCRN (2023)	18.77	29.45	0.42
	HimNet (2024)	20.98	33.00	0.44
	STGODE (2021)	21.40	33.47	0.45
	STG-NCDE (2022)	21.21	33.80	0.45
	STDDE (2024)	22.85	34.26	0.46
Động lực nơ-ron / định hướng vật lý	SGODE (2024)	20.02	32.03	0.42
	AirPhyNet (2024) [†]	21.31	31.77	0.47
	Air-DualODE (2025) [†]	18.64	29.37	0.42
Tham chiếu cùng tập thông tin	AirDDE (2026)	16.92	27.78	0.38
<i>Khối B — Kết quả của nghiên cứu này dưới cùng tập thông tin với AirDDE</i>				
Thiết lập chẩn đoán đề xuất	TSR, trung bình ba mô hình đơn	16.1266 ± 0.0348	—	—
	TSR, trung bình đều ba mô hình	15.8205	24.3253	0.3721

[†] AirDDE dẫn các dòng này từ Air-DualODE; các dòng còn lại được tác giả AirDDE chạy bằng mã chính thức trong thiết lập đa yếu tố. “Crossformer” là tên đã sửa từ lỗi in “Corrformer” trong bảng gốc.
Cách phân nhóm theo họ do nghiên cứu này tổ chức để trình bày; PDFormer được xếp vào nhóm dự báo không gian–thời gian tổng quát. Mã AirDDE tại commit 9277a56 tách khí tượng của cửa sổ đích thành y_{cov} và truyền nó vào hạng nguồn/mất mát cùng decoder, dù công thức trong bài chỉ ghi $M_{1:T}$. So sánh 4,7% dùng trung bình ba mô hình đơn, không dùng ensemble.

6.4 Chẩn đoán chỉ dùng lịch sử

Khoảng cách giữa hai tập thông tin xuất hiện rõ ở Bảng 8. Khi không đọc khí tượng giai đoạn đích, duy trì khí tượng cuối, GRU dự báo khí tượng, mẫu mùa, trạng thái ngoại sinh ẩn hay phân rã đa thang đều dùng quanh MAE 20.5–20.9. Biến thể tốt nhất trong nhóm này, định danh hệ ngoại sinh phân rã, đạt 20.5693, vẫn kém cấu hình dùng khí tượng đích khoảng 3.81 MAE. Trong họ mô hình được khảo sát, chất lượng tác động ngoại sinh tương lai là nút thắt lớn hơn việc tăng dung lượng hay bộ nhớ.

Bảng 8. Chẩn đoán trên tập xác thực theo tập thông tin. Các dòng có dấu * là sàng lọc một hạt giống (43), không phải ước lượng ba hạt giống.

Cách cung cấp tác động ngoại sinh	Đọc khí tượng đích	MAE 1–72 giờ
TSR, khí tượng đã quan trắc	Có	16.7630 ± 0.0252
Duy trì quan trắc khí tượng cuối	Không	20.7945*
GRU khí tượng nhân quả	Không	20.7071*
Trạng thái tác động ẩn	Không	20.7878 ± 0.0952
Mẫu mùa có trọng số	Không	20.8114*
Định danh hệ ngoại sinh phân rã	Không	20.5693*

7 Thảo luận

7.1 Điều quan sát được và điều có thể suy ra

Quan sát 1: đối chứng trực tiếp gần bằng số tham số kém TSR 2.0990 MAE. **Suy luận:** mức cải thiện gắn với cách sinh quỹ đạo tuần tự, không phải với lợi thế về dung lượng hay dữ liệu đầu vào. Kết luận này áp dụng cho cặp kiến trúc được kiểm tra, không phải cho mọi bộ dự báo trực tiếp.

Quan sát 2: các biến thể chỉ dùng lịch sử dừng quanh 20.5–20.9 MAE. **Suy luận:** hướng tiếp theo nên tập trung vào trường khí tượng dự báo thực tế và truyền bất định ngoại sinh vào quỹ đạo PM_{2.5}, thay vì tiếp tục tăng bộ nhớ xác định.

Quan sát 3: trên Beijing, TSR giảm MAE và sMAPE nhưng làm tăng RMSE; khoảng tin cậy theo khối của MAE vẫn cắt 0. **Suy luận:** lợi ích ở sai số điển hình lặp lại ngoài KnowAir, còn các sai số lớn cần được xử lý tốt hơn trước khi khái quát hóa sang những mạng trạm khác.

7.2 Vì sao phân rã đơn giản vẫn hữu ích?

Phân rã trong Phương trình (10) tạo ra hai “đường thoát” rõ ràng cho sai số. Nếu toàn mạng cùng tích tụ, S_k^g có thể nâng nền vùng mà không buộc vận chuyển làm việc trái vai trò. Nếu một trạm lệch khỏi nền, $S_{i,k}^l$ xử lý phần cục bộ nhưng không làm đổi trung bình mạng. Tương tự, phép trừ trung bình ở T_k ngăn đầu vận chuyển học một độ lệch chung để tối ưu nhưng khó diễn giải. Đây là thiên kiến cấu trúc mềm: nó tổ chức không gian nghiệm, không áp đặt một phương trình hóa học hoàn chỉnh.

Phân rã này cung cấp một thiên kiến cấu trúc rõ ràng, còn bằng chứng thực nghiệm trung tâm của nghiên cứu nằm ở so sánh với mô hình sinh trực tiếp gần bằng dung lượng. Đối chứng Beijing bổ sung một phép thử chuyển miền cho cùng kiến trúc TSR.

8 Phạm vi áp dụng và hướng mở rộng

- Khí tượng giai đoạn đích.** Thiết lập chính cô lập bài toán dự báo PM_{2.5} bằng cách điều kiện hóa trên khí tượng tương lai đã quan trắc. Một hệ thống vận hành cần thay đầu vào này bằng trường dự báo khí tượng được hiệu chỉnh và truyền bất định của nó vào dự báo nồng độ.
- So sánh AirDDE chỉ có điểm tổng hợp.** Kiểm toán mã xác nhận AirDDE và TSR có cùng tập thông tin cùng giao thức dữ liệu KnowAir cốt lõi, nên chênh lệch MAE điểm 16.92 so với 16.1266 là so sánh đầu vào công bằng. Tuy nhiên, AirDDE không phát hành dự báo theo cửa sổ, độ biến thiên qua hạt giống hay checkpoint gắn với số công bố; vì vậy không thể lập khoảng tin cậy ghép cặp hoặc kết luận ưu thế thống kê. Việc bài AirDDE viết công thức chỉ dùng lịch sử trong khi mã đọc khí tượng đích cũng làm giảm độ minh bạch của giao thức [Wu et al., 2026].
- Độ rộng dữ liệu ngoài.** Beijing bổ sung một mạng độc lập và giữ đúng tập thông tin, nhưng chỉ có 12 trạm; khoảng tin cậy MAE còn cắt 0 và RMSE đi theo hướng bất lợi. Cần thêm các mạng trạm ở vùng khí hậu và chế độ phát thải khác để đo độ bền chuyển miền.
- Ràng buộc bảo toàn xấp xỉ.** $\sum_i T_{i,k} = 0$ bảo toàn trung bình số học trên các trạm, không phải khối lượng vật chất trong một miền liên tục. Mật độ trạm, thể tích đại diện, biên mở và phản ứng hóa học đều chưa được mô hình hóa đầy đủ.
- Bất định thống kê.** Phương pháp lấy mẫu lại theo khối đã xử lý phụ thuộc thời gian cho cặp trực tiếp/TSR trên Beijing. Chuỗi dự báo của đối chứng trực tiếp khớp dung lượng trên KnowAir không được giữ cùng điểm kiểm tra, nên chênh lệch trung tâm 2.0990 được báo qua ba hạt giống nhưng chưa có khoảng tin cậy ghép cặp theo thời gian.

9 Khả năng tái lập

Mã nguồn lưu toàn bộ phép biến đổi dữ liệu, kiến trúc, hàm mất mát và lệnh huấn luyện. Thí nghiệm được chạy với hạt giống 42, 43 và 44; mỗi cấu hình có điểm kiểm tra riêng. Gói bài báo lưu bảng số liệu nguồn ở định dạng JSON và mã băm SHA-256 của ba điểm kiểm tra lỗi. Đối với Beijing, tệp giao thức ghi mã băm của 12 tệp nguồn, quy tắc xử lý thiếu và phép chia tập; một tệp riêng lưu mã băm điểm kiểm tra cùng quy tắc diễn giải trước lần đánh giá cuối. Bảng 9 ở Phụ lục ghi các siêu tham số cần thiết để tái lập.

Để tránh rò rỉ theo thời gian, chuẩn hóa chỉ khớp trên phần huấn luyện; cửa sổ lịch sử và đích nằm trọn trong từng phân đoạn; điểm kiểm tra mô hình được chọn bằng MAE xác thực. Kết quả kiểm tra TSR dùng `scripts/evaluate_tsr_primary.py`;

đối chứng ngoài dùng `scripts/prepare_beijing_multisite.py` và `scripts/evaluate_external_pair.py`. Mã AirDDE công khai được kiểm toán từ <https://github.com/w2obin/airdde-aaai> tại commit 9277a56db4bcc0e5e6a3a78bc9. kết luận về khí tượng đích dựa trên đường dữ liệu và lời gọi mô hình ở phiên bản này. Ma trận KnowAir tham chiếu chạy với Python 3.11, PyTorch 2.8.0 và CUDA 12.8; thí nghiệm Beijing chạy với Python 3.11, PyTorch 2.13.0 và MPS. Kiến trúc được chọn trên tập xác thực; do tập kiểm tra KnowAir đã từng được xem trong quá trình phát triển dự án, các số kiểm tra được trình bày như đánh giá cuối của cấu hình đã chọn, không dùng để tinh chỉnh thêm. Kho ấn danh cùng định danh phiên bản lưu trữ sẽ được bổ sung trước khi nộp.

10 Kết luận

Nghiên cứu cho thấy dự báo PM_{2.5} 72 giờ có điều kiện trên khí tượng đích được hưởng lợi khi được viết như một quá trình tiến hóa trạng thái thay vì sinh toàn bộ chân trời trực tiếp từ một biểu diễn lịch sử cố định. Bằng chứng trung tâm là đối chứng trực tiếp gần bằng dung lượng và dùng cùng tập thông tin: MAE xác thực KnowAir giảm từ 18.8620 xuống 16.7630. Trên Beijing độc lập, lợi ích lặp lại ở MAE và sMAPE nhưng không ở RMSE, qua đó xác định rõ hướng cần cải thiện đối với các sai số cực trị. Khoảng cách lớn của các biến thể chỉ dùng lịch sử đặt ưu tiên tiếp theo vào khí tượng dự báo thực tế và lan truyền bất định ngoại sinh.

A Siêu tham số và môi trường tái lập

Bảng 9. Siêu tham số của TSR và đối chứng trực tiếp.

Thành phần	TSR	Đối chứng trực tiếp
Chiều ẩn	64	84
Chiều nhúng trạm	8	10
Chiều đầu toán tử / nhúng chân trời	32 / 8	— / 20
Số tầng giềng	8	—
Thang suy giảm khoảng cách	250 km	—
Chặn mỗi gia số thành phần	0.5 đơn vị chuẩn hóa	—
Số tham số	72.435	72.630
Hàm mất mát	Hàm ghép MAE, Phương trình (11)	Hàm ghép MAE, Phương trình (11)
Bộ tối ưu	AdamW	AdamW
Tốc độ học ban đầu	10^{-3}	3×10^{-3}
Suy giảm trọng số	10^{-5}	10^{-5}
Cỡ lô	256	256
Số vòng tối đa / dừng sớm	30 / 6	30 / 6
Hệ số giảm tốc độ học	0.5	0.5
Chuẩn cắt đạo hàm	5.0	5.0
Hạt giống	42, 43, 44	42, 43, 44
Chỉ số chọn điểm kiểm tra	MAE xác thực 1–72 giờ	MAE xác thực 1–72 giờ

Tuyên bố

Dữ liệu và mã nguồn. KnowAir được phát hành cùng PM_{2.5}-GNN [Wang et al., 2020]; Beijing Multi-Site được UCI phát hành theo giấy phép CC BY 4.0 [Chen, 2017]. Đường dẫn kho mã ấn danh, định danh phiên bản lưu trữ và giấy phép phần mã sẽ được bổ sung trong bản nộp.

Xung đột lợi ích, tài trợ và đóng góp tác giả. Các tuyên bố này sẽ được hoàn thiện theo biểu mẫu của tạp chí đích trước khi nộp.

Tài liệu

- Ling Chen, Kun Wu, Jiajie Lou, and Junchi Liu. Signed graph neural ordinary differential equation for modeling continuous-time dynamics. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 8292–8301, 2024a.
- Ling Chen, Jiahui Xu, Binqing Wu, and Jianlong Huang. Group-aware graph neural network for nationwide city air quality forecasting. *ACM Transactions on Knowledge Discovery from Data*, 18(3):1–20, 2024b.
- Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- Song Chen. Beijing multi-site air quality, 2017. URL <https://archive.ics.uci.edu/dataset/501/beijing+multi+site+air+quality+data>.
- Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using RNN encoder–decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*, pages 1724–1734, 2014. doi: 10.3115/v1/D14-1179.
- Jeongwhan Choi, Hyeongjin Choi, Jeehyun Hwang, and Noseong Park. Graph neural controlled differential equations for traffic forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 6367–6374, 2022.
- Zheng Dong, Renhe Jiang, Haotian Gao, Huaxiu Liu, Jinliang Deng, Qingsong Wen, and Xuan Song. Heterogeneity-informed meta-parameter learning for spatiotemporal time series forecasting. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 631–641, 2024.
- Zheng Fang, Qingqing Long, Guojie Song, and Kunqing Xie. Spatial-temporal graph ODE networks for traffic flow forecasting. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 364–373, 2021.
- Shengnan Guo, Youfang Lin, Ning Feng, Chao Song, and Huaiyu Wan. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 922–929, 2019.
- Kethmi Hirushini Hettige, Jiahao Ji, Shili Xiang, Cheng Long, Gao Cong, and Jingyuan Wang. AirPhyNet: Harnessing physics-guided neural networks for air quality prediction. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=JW3jTjaaAB>.
- Jiawei Jiang, Chengkai Han, Wayne Xin Zhao, and Jingyuan Wang. PDFormer: Propagation delay-aware dynamic long-range transformer for traffic flow prediction. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 4365–4373, 2023a.
- Renhe Jiang, Zhaonan Wang, Junyao Yong, Philip Jeph, Quanjun Chen, Yasushi Kobayashi, Xuan Song, Shintaro Fukushima, and Toyotaro Suzumura. Spatio-temporal meta-graph learning for traffic forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 8078–8086, 2023b.
- Yaguang Li, Rose Yu, Cyrus Shahabi, and Yan Liu. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In *The Sixth International Conference on Learning Representations*, 2018.
- Zhe Li, Zeyu Hu, Peng Han, Yuxuan Gu, and Shuo Cai. SSL-STMFormer: Self-supervised learning spatio-temporal entanglement transformer for traffic flow prediction. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 12130–12138, 2025.
- Yuxuan Liang, Yutong Xia, Songyu Ke, Yiwei Wang, Qingsong Wen, Junbo Zhang, Yu Zheng, and Roger Zimmermann. AirFormer: Predicting nationwide air quality in china with transformers. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 14329–14337, 2023. doi: 10.1609/aaai.v37i12.26676.
- Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. iTransformer: Inverted transformers are effective for time series forecasting. In *The Twelfth International Conference on Learning Representations*, 2024.

- Qingqing Long, Zheng Fang, Chen Fang, Chong Chen, Pengfei Wang, and Yanjie Zhou. Unveiling delay effects in traffic forecasting: A perspective from spatial-temporal delay differential equations. In *Proceedings of the ACM Web Conference*, pages 1035–1044, 2024.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *The Seventh International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=Bkg6RiCqY7>.
- Yuan Qi, Qi Li, Hossein Karimian, and Di Liu. A hybrid model for spatiotemporal forecasting of PM_{2.5} based on graph convolutional neural network and long short-term memory. *Science of the Total Environment*, 664:1–10, 2019. doi: 10.1016/j.scitotenv.2019.01.333.
- John H. Seinfeld and Spyros N. Pandis. *Atmospheric Chemistry and Physics: From Air Pollution to Climate Change*. Wiley, 3 edition, 2016. ISBN 9781118947401.
- Jindong Tian, Yuxuan Liang, Ronghui Xu, Peng Chen, Chenjuan Guo, Aoying Zhou, Lujia Pan, Zhongwen Rao, and Bin Yang. Air quality prediction with physics-guided dual neural ODEs in open systems. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=k0Jf7Dklyv>.
- Shuo Wang, Yanran Li, Jiang Zhang, Qingye Meng, Lingwei Meng, and Fei Gao. PM_{2.5}-GNN: A domain knowledge enhanced graph neural network for PM_{2.5} forecasting. In *Proceedings of the 28th International Conference on Advances in Geographic Information Systems*, pages 163–166, 2020. doi: 10.1145/3397536.3422208.
- Binqing Wu, Zongjiang Shang, Shiyu Liu, Jianlong Huang, Jiahui Xu, and Ling Chen. AirDDE: Multifactor neural delay differential equations for air quality forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 40, pages 15941–15949, 2026. doi: 10.1609/aaai.v40i19.38627.
- Zonghan Wu, Shirui Pan, Guodong Long, Jing Jiang, Xiaojun Chang, and Chengqi Zhang. Connecting the dots: Multivariate time series forecasting with graph neural networks. In *Proceedings of the 26th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 753–763, 2020.
- Jiahui Xu, Ling Chen, Mingqi Lv, Chaoqun Zhan, Sanjian Chen, and Jian Chang. HighAir: A hierarchical graph neural network-based air quality forecasting method. *arXiv preprint arXiv:2101.04264*, 2021. doi: 10.48550/arXiv.2101.04264.
- Bing Yu, Haoteng Yin, and Zhanxing Zhu. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. In *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*, pages 3634–3640, 2018.
- Yunhao Zhang and Junchi Yan. Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting. In *The Eleventh International Conference on Learning Representations*, 2023.
- Haoming Zhou, Fang Zhang, Zhenhong Du, and Rui Liu. A theory-guided graph networks based PM_{2.5} forecasting method. *Environmental Pollution*, 293:118569, 2022. doi: 10.1016/j.envpol.2021.118569.